查看處理進度 ↗

# 本週 10 個候選議題

8 個 quantization、2 個 speculative decoding；與上週零重複。EAGLE-3 與 LPBQ 為協作／驗收候選，先確認既有負責人的進度。此批尚未選定。

01 (speculative decoding) · feat · issue 20431 · 第 2、3 頁
釐清推測解碼的 KV commit／rollback 契約

02 (speculative decoding) · feat · issue 19784 · 第 4、5 頁
檢查 EAGLE-3 的驗收與既有 runner 整合缺口

03 (quantization) · bug · issue 24125 · 第 6、7 頁
定位 QNN 16a8w 的 gather 輸出讀值錯誤

04 (quantization) · feat · issue 22431 · 第 8、9 頁
補 Vulkan INT8 weight 的 per-token activation 路徑

05 (quantization) · feat · issue 13476 · 第 10、11 頁
釐清並補齊 Vulkan 動態 INT8 convolution

06 (quantization) · feat · issue 13063 · 第 12、13 頁
對齊 NXP Conv／MatMul 與 activation 的量化邊界

07 (quantization) · bug · issue 12341 · 第 14、15 頁
重新定位 MobileBert／Albert 的 XNNPACK 量化阻塞

08 (quantization) · bug · issue 19132 · 第 16、17 頁
查核 QNN 混合精度的 partition 與 FP16 邊界

09 (quantization) · bug · issue 23922 · 第 18、19 頁
協作定位 QNN LPBQ stride-2 convolution＋ReLU 失敗

10 (quantization) · feat · issue 9515 · 第 20、21 頁
補齊量化到品質驗證的端到端文件缺口

# 01. (speculative decoding) 釐清推測解碼的 KV commit／rollback 契約

原始議題 ↗

## 問題釐清

RFC 希望同一份模型能切換一般解碼與 tree／speculative decoding。候選 token 被拒絕後，KV 狀態必須保持正確；留言另提出 ring-buffer eviction、每層 head 數不同，以及 export-time 靜態 KV 量化的需求。

## 可能解法

建議先縮小到 SeqCache／TreeCache 的介面與正確性案例，驗證 propose、commit、分支遮罩與拒絕後續接。靜態 KV 量化如何參與 runtime 控制仍待 RFC 討論，不直接承諾整套跨 backend 實作。

## 應用場景

需要 EAGLE 類推測解碼、prefix 分支或 agent 工作流的桌面端 runner；RFC 提及 MLX、XNNPACK 與 Vulkan。切入點是契約與測試，硬體實作另議。

## 專有名詞介紹

KV cache：保留先前 token 的注意力資料。Commit／rollback：保留接受的候選、撤回被拒絕候選的狀態。Tree mask：限定每個分支可讀取的歷史。

# 01. (speculative decoding) 釐清推測解碼的 KV commit／rollback 契約

原始議題 ↗

## 重點功能

定義可支援一般及 tree／speculative decoding 的 cache 契約；先處理一個可驗證的子範圍。

## Input

模型架構資訊、token 位置、候選樹與接受的路徑；靜態 KV 量化參數的傳遞方式待釐清。

## Output

可核對接受／拒絕後狀態的介面與測試，不把 RFC 文字當作已完成的 runtime。

# 02. (speculative decoding) 檢查 EAGLE-3 的驗收與既有 runner 整合缺口

原始議題 ↗ 關閉的相關 PR ↗

## 問題釐清

RFC 規劃在 TextLLMRunner 下加入 EAGLE-3，涵蓋 draft、target verify、接受／拒絕與 KV 正確性。留言曾指向 PR 20157；該 PR 已關閉且未合併，不能據此宣稱整項功能已完成或完全沒有人做。

## 可能解法

先盤點目前 runner 與其他 speculative PR 的已實作範圍，和原作者確認尚缺的驗收案例。候選切入點是 greedy 等價性、部分／全部接受、拒絕後 KV 與 EOS／token budget；不另開競爭性全功能實作。

## 應用場景

RFC 的 P0 指向 Gemma4、batch size 1、固定 chain 長度與 CUDA／MLX。這是協作與驗收候選，需確認可用模型、硬體及原作者意願後再開發。

## 專有名詞介紹

EAGLE-3：利用較小 draft 模型提案，再由 target 驗證。Rejection sampling：修正提案分布的接受／拒絕取樣。Lossless：輸出符合 target 的解碼語義。

# 02. (speculative decoding) 檢查 EAGLE-3 的驗收與既有 runner 整合缺口

原始議題 ↗ 關閉的相關 PR ↗

## 重點功能

沿用既有 runner 的 tokenizer、prefill、callback 與統計，確認推測生成策略尚缺的可驗收子項。

## Input

Target／draft PTE、draft 機率、所需 hidden states、KV 狀態與生成參數。

## Output

經協調後的缺口清單與 target 語義一致性測試；不把曾關閉的 PR 當作可直接接手的任務。

協作／驗收候選；先查既有進度。PR 20157 closed、merged=false；不推薦重做整套。

# 03. (quantization) 定位 QNN 16a8w 的 gather 輸出讀值錯誤

原始議題 ↗

## 問題釐清

回報的 16a8w 圖中，cos／sin 經 gather 後供兩個 RoPE 使用；只通往 graph output 的最後 consumer 讀值錯誤。回報 output 2 的相對誤差約 0.77，host QDQ 約 0.0017；FP16 與直接傳入 cos／sin 不受影響。

## 可能解法

建議用原有最小圖比較 gather、consumer 與 graph output 的 lowering／記憶體生命週期。先在目前 main 重現，再定位 QNN delegate／SDK 邊界；記憶體別名或生命週期目前只是調查方向。

## 應用場景

SM8850／Galaxy S26 Ultra、QAIRT 2.47 的量化 TTS／RoPE 圖。回報基於 1.4.1 fork，尚未查核 main；裝置驗證是必要成本。

## 專有名詞介紹

16a8w：16-bit activation、8-bit weight。Gather：按索引取表格列。RoPE：旋轉位置編碼。QDQ：量化再反量化的參考圖。

未指派、無留言；未查得 timeline 修復 PR。須先在 main 與裝置重現。

# 03. (quantization) 定位 QNN 16a8w 的 gather 輸出讀值錯誤

原始議題 ↗

## 修正前

相同 gather 結果的最後 consumer 只輸出到圖外時，量化輸出出現大誤差。

## 修正後（預期）

同一最小圖各個輸出應與參考值落在已定義的量化誤差範圍內。

未指派、無留言；未查得 timeline 修復 PR。須先在 main 與裝置重現。

# 04. (quantization) 補 Vulkan INT8 weight 的 per-token activation 路徑

原始議題 ↗ 已合併的文字修正 ↗

## 問題釐清

回報指出 Vulkan 動態 activation 量化實際是 per-tensor；Transformer encoder embedding 的精度較 per-token 控制組差。PR 22432 已合併，但只修正註解，沒有實作 per-token INT8 weight kernel。

## 可能解法

建議先定義 per-token activation 與 INT8 weight 的資料契約，再對齊 quantizer、pattern 與 runtime kernel。以 eager／QDQ／delegate 三段比對，避免把註解修正重當成未完成工作。

## 應用場景

Vulkan 上的句向量與 Transformer encoder；需能跑 Vulkan 的裝置。回報提到 issue 22372 的 scalar／embedding 前置問題，開始前需重新確認其狀態。

## 專有名詞介紹

Per-tensor：整個輸入共用 scale。Per-token：每列 token 有自己的量化尺度。Cosine similarity：比較兩個 embedding 的方向是否接近。

# 04. (quantization) 補 Vulkan INT8 weight 的 per-token activation 路徑

原始議題 ↗ 已合併的文字修正 ↗

## 重點功能

支援與 INT8 weight 搭配的 per-token 動態 activation 量化，並建立精度比較。

## Input

Transformer activation、INT8 weights、每個 token 的量化參數與測試模型。

## Output

一致的 quantizer／kernel 路徑與量化誤差結果；效能提升需另行量測。

未指派；PR 22432 僅完成文字修正，功能缺口仍由原 issue 追蹤。

# 05. (quantization) 釐清並補齊 Vulkan 動態 INT8 convolution

原始議題 ↗

## 問題釐清

議題直接要求 Vulkan backend 的動態量化 8-bit convolution，未提供輸入形狀、支援的 convolution 變體或驗收模型。它是功能需求，不能假裝已取得失敗重現。

## 可能解法

先核對目前 main 的既有 conv／量化 kernel，再確認 activation granularity、weight layout 與支援範圍。若缺口仍在，以單一 convolution 變體開始，補 partition、shader 與數值測試。

## 應用場景

希望在 Vulkan GPU 上執行量化 CNN 的使用者。需要 Vulkan runtime／GPU；模型與 stride、padding 等組合由需求澄清後決定。

## 專有名詞介紹

動態量化：執行時依 activation 求量化參數。Convolution：影像模型常用的卷積運算。Shader：GPU 上執行 kernel 的程式。

# 05. (quantization) 釐清並補齊 Vulkan 動態 INT8 convolution

原始議題 ↗

## 重點功能

Vulkan backend 的動態 INT8 convolution 支援；具體變體與 granularity 待釐清。

## Input

輸入 activation、量化 weights、convolution 參數；精確 dtype／layout 契約待確認。

## Output

可委派到 Vulkan 的運算與對應數值測試；不承諾未定義的全面覆蓋。

# 06. (quantization) 對齊 NXP Conv／MatMul 與 activation 的量化邊界

原始議題 ↗ 相關 HardTanh 修正 ↗

## 問題釐清

Neutron Quantizer 目前將 activation 分開量化；原議題指出 NPU 可把 Conv／MatMul 與後續 activation 合為一次計算，因此需要 DQ → Conv → Activation → Q 的量化邊界。

## 可能解法

建議挑一個 activation pattern，對照 annotation 與融合後的圖，確認共享 qparams 的規則並補回歸測試。相關 PR 12893 已修 HardTanh 的一部分設定，不能把它算作整個融合需求已解決。

## 應用場景

NXP Neutron NPU 的量化 CNN 或含 MatMul 的模型；主機可先驗證圖結構，最終執行仍需相容 backend／裝置。

## 專有名詞介紹

Qparams：scale、zero point 等量化參數。Fusion：多個運算由同一個 backend 路徑執行。Annotation：在圖中描述量化規則。

未指派；有 NXP 內部追蹤 ID。先確認相關局部修正及 backend 維護者需求。

# 06. (quantization) 對齊 NXP Conv／MatMul 與 activation 的量化邊界

原始議題 ↗　相關 HardTanh 修正 ↗

## 重點功能

依 Conv／MatMul 後接 activation 的模式，產生符合 Neutron 融合語義的量化區段。

## Input

包含相鄰 Conv／MatMul 與 activation 的 exported graph、量化設定與校正資料。

## Output

正確的 Q／DQ 邊界、量化參數與圖結構測試；裝置精度需另驗證。

未指派；有 NXP 內部追蹤 ID。先確認相關局部修正及 backend 維護者需求。

# 07. (quantization) 重新定位 MobileBert／Albert 的 XNNPACK 量化阻塞

原始議題 ↗

## 問題釐清

原議題記錄 MobileBert 與 Albert 的量化 CI 被關閉，留言也回報量化 MobileBert 無法產生 PTE；embedding 被提出為可能方向，但未獲確認。舊版本錯誤不代表目前 main 仍相同。

## 可能解法

建議先檢查目前 CI 設定，使用標準 export／test 工具確認兩個模型能否量化與執行。僅在問題仍可重現時定位 unsupported pattern／embedding，補測試後再恢復對應 CI。

## 應用場景

希望把 BERT 類文字編碼器部署到 XNNPACK CPU 的開發者。歷史留言提及 v0.6.0-rc6-android；目前版本適用性是首要查核點。

## 專有名詞介紹

XNNPACK：CPU 運算 backend。Embedding：將 token index 轉成向量。PTE：ExecuTorch 的部署程式檔。

未指派；留言曾請維護者調查，未查得 timeline 修復 PR。須先驗證時效。

# 07. (quantization) 重新定位 MobileBert／Albert 的 XNNPACK 量化阻塞

原始議題 ↗

## 修正前

歷史回報中，兩個模型的量化 CI 停用，量化 MobileBert 匯出受阻；目前 main 待重現。

## 修正後（預期）

若缺陷仍存在，修正後能用標準流程量化、匯出並執行，並恢復相應測試。

未指派；留言曾請維護者調查，未查得 timeline 修復 PR。須先驗證時效。

# 08. (quantization) 查核 QNN 混合精度的 partition 與 FP16 邊界

原始議題 ↗

## 問題釐清

回報在同一 QNN 圖混用量化與 FP16 計算時 graph prepare 失敗。討論進一步聚焦 Qwen3.5 DeltaNet 的 L2-normalize、sigmoid、softplus；CPU fallback 約造成 20 次 graph break。

## 可能解法

先依維護者建議區分 FP16 activation／quantized weight，與整個 FP16 區段。比較 skip_annotation 分圖與 backend 可支援的 FP16a4w／FP16a8w 路徑；不要承諾 SDK 不支援的同一 partition 混用。

## 應用場景

Snapdragon 8 Gen 5 上的 Qwen3.5 精度敏感區段。需要 QAIRT／HTP 環境與裝置；應先取得最小 operator 子圖，不直接重做整個模型。

## 專有名詞介紹

Mixed precision：不同區段使用不同位元精度。Partition：交由同一 delegate 執行的子圖。Graph break：分圖後可能增加資料往返成本。

未指派；維護者仍在釐清 FP16 需求與子圖。方案需配合 SDK 支援範圍。

# 08. (quantization) 查核 QNN 混合精度的 partition 與 FP16 邊界

原始議題 ↗

## 修正前

量化與 FP16 敏感運算組合在 graph prepare 出錯，或必須大量切回 CPU。

## 修正後（預期）

對已確認支援的子圖可正確執行；不支援組合應清楚診斷或合理分圖，並量測精度與成本。

未指派；維護者仍在釐清 FP16 需求與子圖。方案需配合 SDK 支援範圍。

# 09. (quantization) 協作定位 QNN LPBQ stride-2 convolution＋ReLU 失敗

原始議題 ↗

## 問題釐清

SM8850 上，16a4w_block 的 stride-2 convolution 後接 ReLU，在 block size 16／32／64 都無法完成 HTP graph prepare，錯誤為 Relu16bParamsPlaceholder。stride 1、去掉 ReLU、改用 per-channel 16a4w 則可通過。

## 可能解法

這題已有 psiddh 指派，僅建議協作重現與縮小問題。比較 LPBQ pattern、activation 量化參數與 SDK graph prepare；若屬 SDK 缺口，提供精簡案例，不自行宣稱改 Python annotation 就能修好。

## 應用場景

SM8850／V81、QAIRT 2.47 的 ResNet 類 CNN。原最小案例使用 256→128 channel convolution；需要 SDK 與相容目標驗證。

## 專有名詞介紹

LPBQ：以 block 表示低精度 weight 的量化方式。Stride 2：降低空間解析度的卷積步幅。HTP graph prepare：SDK 為 NPU 建立可執行圖。

協作候選，已指派 psiddh；未查得 timeline 修復 PR。先對齊負責人，不宣稱可自由接手。

# 09. (quantization) 協作定位 QNN LPBQ stride-2 convolution＋ReLU 失敗

原始議題 ↗

## 修正前

上述 stride-2＋ReLU＋LPBQ 組合無法產生 QNN context binary。

## 修正後（預期）

支援的組合可完成 prepare 並驗證數值；若 SDK 不支援，應提供明確限制或受測替代路徑。

協作候選，已指派 psiddh；未查得 timeline 修復 PR。先對齊負責人，不宣稱可自由接手。

# 10. (quantization) 補齊量化到品質驗證的端到端文件缺口

原始議題 ↗

## 問題釐清

議題要求整理 PT2E 的 PTQ／QAT／品質驗證，以及 quantize_ 的 GPTQ／PARQ 研究流程。原文是文件需求，沒有可引用的失敗輸出；需先盤點目前文件已覆蓋哪些內容。

## 可能解法

建議選一個仍欠缺的可執行流程，沿用官方 CLI／測試工具連接校正、轉換、export 與品質比較，列出版本及 backend 限制。既有文件已完整覆蓋的章節不重寫。

## 應用場景

第一次在 ExecuTorch 選擇量化策略、比較模型品質的使用者。以有公開可取得輸入與模型的流程為主，避免只有內部資源能重跑。

## 專有名詞介紹

PTQ：訓練後量化。QAT：訓練時模擬量化。GPTQ／PARQ：不同的進階量化流程。品質驗證：比較量化後與參考模型的結果。

# 10. (quantization) 補齊量化到品質驗證的端到端文件缺口

原始議題 ↗

## 重點功能

連接 PT2E PTQ／QAT 與品質驗證，並說明 quantize_ 進階流程的適用性。

## Input

已確認的官方工具、模型與資料來源、量化設定及比較指標。

## Output

能逐行執行與驗證的量化指南；需先確認缺口，不以自製 harness 取代正式工具。

未指派、無留言或 timeline 修復連結；文件缺口需對照目前 main 確認。