本週 10 個候選議題

7 個 build operator、3 個 quantization；依需求明確度與可切入範圍排序。候選尚未選定。

01 (quantization) • bug • issue 24434 • 第 2、3 頁
修正 QNN fp16a8w 的 LayerNorm 標註崩潰

02 (build operator) • bug • issue 24767 • 第 4、5 頁
補 CUDA nonzero 與 masked_select fallback

03 (build operator) • bug • issue 24671 • 第 6、7 頁
讓 CPU 廣播運算依輸出 strides 寫入

04 (build operator) • feat • issue 11416 • 第 8、9 頁
補 cumsum 的複數 dtype 與測試

05 (build operator) • feat • issue 15658 • 第 10、11 頁
把 SLEEF 接入 CMake 向量化 kernel 建置

06 (quantization) • feat • issue 9847 • 第 12、13 頁
為 CoreMLQuantizer 增加 4-bit affine 支援

07 (build operator) • feat • issue 13748 • 第 14、15 頁
在 AOT 階段整理 CMSIS-NN 廣播 kernel 選擇

08 (build operator) • feat • issue 9010 • 第 16、17 頁
用模型需求縮小 delegate kernel 建置範圍

09 (quantization) • bug • issue 16426 • 第 18、19 頁
釐清 Arm 量化前後的數值偏差來源

10 (build operator) • feat • issue 11424 • 第 20、21 頁
釐清並補 _linalg_solve_ex 的複數支援

01. (quantization) 修正 QNN fp16a8w 的 LayerNorm 標註崩潰

原始議題 ↗ 現行 LayerNorm 標註 ↗

問題釐清

Linear 接 LayerNorm 使用 fp16a8w 時，prepare_pt2e 會讀取 None.dtype 而中止；目前 LayerNorm 標註程式仍有這個存取。

可能解法

候選修法：比照 MatMul，先判斷 activation qspec 是否存在，再讀 dtype。議題作者回報兩種權重配置可通過；本次未實測。

應用場景

使用 Qualcomm HTP 混合精度量化、在主機端匯出含 LayerNorm 模型的人；問題發生於標註，尚未進入裝置推論。

專有名詞介紹

fp16a8w：16 位元浮點 activation 搭配 8 位元權重。qspec：量化規格；LayerNorm：對特徵做正規化。

01. (quantization) 修正 QNN fp16a8w 的 LayerNorm 標註崩潰

原始議題 ↗ 現行 LayerNorm 標註 ↗

修正前

make_quantizer(use_fp16a8w) 處理 Linear＋LayerNorm 時，input_activation 為 None，卻被當成具有 dtype 的規格讀取，產生 AttributeError。

修正後（預期）

同一模型應完成 prepare_pt2e 標註，正確保留未量化 activation 與權重量化設定；需驗證 per-tensor、per-channel，以及既有整數量化配置。

切入點明確；尚未查得承接者或修復 PR；裝置數值驗收另行確認。

02. (build operator) 補 CUDA nonzero 與 masked_select fallback

原始議題 ↗

問題釐清

直接呼叫 nonzero 或 masked_select 的模型在 CUDA lowering 時回報缺少 fallback kernel；一般布林索引可匯出，不能據此認定直接呼叫已支援。

可能解法

候選修法：參照既有 CUDA shim 補兩個 AOTI 入口，核對資料相依輸出大小與錯誤回報；尚無本次執行證據。

應用場景

將模型轉成顯式運算子的工具與 CUDA 部署者；作者以 H100、ExecuTorch 1.6.0+cu132、torch 2.15.0+cu132 回報。

專有名詞介紹

AOTI：預先編譯模型所用的執行介面。shim：銜接呼叫的薄層。fallback kernel：編譯器未直接產生時使用的運算實作。

與 portable nonzero layout 修復不同；目前未查得對應 CUDA shim 實作 PR。

02. (build operator) 補 CUDA nonzero 與 masked_select fallback

原始議題 ↗

修正前

直接 nonzero(x > 0).sum() 或 masked_select(x, x > 0).sum() 會因 aoti_torch_cuda_nonzero／masked_select 缺漏而停止 lowering。

修正後（預期）

兩種直接呼叫應可完成 CUDA 匯出與執行，結果符合 PyTorch；包含空選取與不同非零元素數量。驗收範圍需涵蓋資料相依形狀。

與 portable nonzero layout 修復不同；目前未查得對應 CUDA shim 實作 PR。

03. (build operator) 讓 CPU 廣播運算依輸出 strides 寫入

原始議題 ↗ 相鄰 complex div PR ↗ 共用 elementwise helper ↗

問題釐清

channels-last 輸入做逐元素廣播時，共用 helper 將邏輯序號當成實體輸出位置；作者的乘法案例把中間兩個結果寫反，contiguous 對照正常。

可能解法

候選修法：輸出位址也依 strides 計算，並檢查無廣播與向量化捷徑的 layout 相容性；需覆蓋 binary、ternary 與 optimized where。

應用場景

使用 CPU portable／optimized kernels 與 channels-last 張量的部署者。回報涵蓋 float32、int32、bool；未使用 delegate。

專有名詞介紹

strides：每個維度在記憶體中的步距。廣播：重用較小輸入的值。channels-last：通道資料相鄰的記憶體排列。

影響面較廣；相鄰 complex div PR 已存在，修改共用 helper 前需協調。

03. (build operator) 讓 CPU 廣播運算依輸出 strides 寫入

原始議題 ↗ 相鄰 complex div PR ↗ 共用 elementwise helper ↗

修正前

輸入 a=[1,2,3,4]、b=[10,20] 依議題指定形狀轉成 channels-last 後，相乘應為 [10,20,60,80]，卻得到 [10,60,20,80]。

修正後（預期）

同一輸入應與 PyTorch 結果一致，且 contiguous 對照不退化；須驗證受共用 helper 影響的二元、三元與比較運算，不能只修乘法。

影響面較廣；相鄰 complex div PR 已存在，修改共用 helper 前需協調。

04. (build operator) 補 cumsum 的複數 dtype 與測試

原始議題 ↗ 目前 cumsum kernel ↗ ATen schema ↗

問題釐清

議題要求 cumsum 的複數支援；目前 Edge 型別清單與 portable dispatch 仍限實數等型別。這是特定運算子的型別覆蓋工作。

可能解法

候選路徑：一起核對 Edge schema、dtype 轉換與累加實作，補與 PyTorch 對照的測試；不能只擴大 dispatch 巨集。

應用場景

在 CPU 執行複數訊號或頻域資料的累積和；議題未指定硬體、效能目標或最小重現，這些條件待釐清。

專有名詞介紹

複數：同時保存實部與虛部。cumsum：沿指定維度逐項累加。dtype：張量元素的數值型別。

04. (build operator) 補 cumsum 的複數 dtype 與測試

原始議題 ↗ 目前 cumsum kernel ↗ ATen schema ↗

重點功能

讓 cumsum 能處理約定範圍的複數 dtype，並有數值與邊界案例測試；精確支援集合待釐清。

Input

複數張量、dim，以及可選 dtype；介面依 ATen schema。空張量、負維度與型別轉換的驗收範圍待確認。

Output

與輸入形狀相同的累積和張量，數值應符合 PyTorch；輸出 dtype 與誤差容許值需明訂。

05. (build operator) 把 SLEEF 接入 CMake 向量化 kernel 建置

原始議題 ↗ 已合併的巨集修正 ↗ optimized CMake ↗

問題釐清

議題指出部分向量化 kernel 需要 SLEEF，支援集中於 Buck；目前 optimized CMake 目標仍未直接宣告 SLEEF 相依與連結。

可能解法

候選路徑：釐清架構與選項，補 CMake 相依、編譯定義及連結，再量測。已合併的巨集名稱修正不等於完成 CMake 整合。

應用場景

以 CMake 建置 optimized CPU kernels、需要向量化 exp／log 等數學運算的使用者；目標架構與交叉編譯矩陣待定。

專有名詞介紹

SLEEF：向量化數學函式庫。SIMD：一條指令處理多筆資料。Buck／CMake：不同的建置系統。

05. (build operator) 把 SLEEF 接入 CMake 向量化 kernel 建置

原始議題 ↗ 已合併的巨集修正 ↗ optimized CMake ↗

重點功能

讓適用的 CMake optimized kernel 建置可使用 SLEEF，並明確定義啟用條件；不預設尚未量測的加速幅度。

Input

CMake 建置設定、目標 CPU 架構與 SLEEF 相依；來源取得方式與預設啟用策略待釐清。

Output

可成功編譯與連結的 kernel 程式庫；測試確認適用路徑使用 SLEEF，數值及效能結果可供比較。

06. (quantization) 為 CoreMLQuantizer 增加 4-bit affine 支援

原始議題 ↗ 目前標註設定 ↗

問題釐清

議題要求 PT2E CoreMLQuantizer 支援 4-bit affine，涵蓋 groupwise 與 channelwise；目前標註設定沒有明確的四位元範圍或分組規格。

可能解法

候選路徑：先與 Core ML 的權重量化介面對齊，再補規格、標註與匯出驗證；支援的運算子、group size 與部署版本仍待確認。

應用場景

希望用較低位元權重部署 Apple 裝置模型的人；不能把其他 Core ML 壓縮 API 的四位元能力當作這條 PT2E 路徑已支援。

專有名詞介紹

affine 量化：以 scale 與 zero point 映射數值。groupwise：每組權重共用參數；channelwise：每通道各有參數。

議題正文簡短；groupwise／channelwise 來自標題，其餘介面條件待確認。

06. (quantization) 為 CoreMLQuantizer 增加 4-bit affine 支援

原始議題 ↗ 目前標註設定 ↗

重點功能

在 PT2E CoreMLQuantizer 提供 4-bit affine 的 groupwise 與 channelwise 量化；先確認是權重範圍及支援運算子集合。

Input

可匯出的模型與四位元量化設定；分組大小、通道軸、校準方式及 activation 精度待釐清。

Output

能沿 Core ML 匯出路徑使用的量化模型；需驗證數值、檔案大小及目標版本相容性，尚無既定驗收門檻。

議題正文簡短；groupwise／channelwise 來自標題，其餘介面條件待確認。

07. (build operator) 在 AOT 階段整理 CMSIS-NN 廣播 kernel 選擇

原始議題 ↗ 早期 add 修正 ↗ 目前 quantized_add ↗

問題釐清

議題希望把 CMSIS-NN 的廣播 kernel 選擇整理為 pass。現有 quantized_add 已有特定 channel broadcast 路徑，不能描述為完全沒有廣播支援。

可能解法

候選路徑：先界定現有相容形狀，再把選擇條件放進 broadcast 或獨立 pass；一般廣播是否展開、拷貝或保留 CPU 路徑須討論。

應用場景

將量化模型部署到 Cortex-M、需要在 AOT 選擇 CMSIS-NN 加速 kernel 的開發者；新增拷貝可能增加 MCU 記憶體成本。

專有名詞介紹

AOT：執行前完成轉換。pass：一次圖形轉換。CMSIS-NN：Arm 微控制器的神經網路 kernel 函式庫。

已有部分 runtime 支援；本題為 AOT 選擇邏輯，須先與維護者確認剩餘範圍。

07. (build operator) 在 AOT 階段整理 CMSIS-NN 廣播 kernel 選擇

原始議題 ↗ 早期 add 修正 ↗ 目前 quantized_add ↗

重點功能

將 CMSIS-NN kernel 的廣播適用性與選擇邏輯整理成清楚的 AOT pass；支援形狀和無法加速時的行為待釐清。

Input

含廣播運算的量化圖、張量形狀與目標 kernel 能力；不能只憑兩個輸入大小不同就判定可用。

Output

選到相容 kernel 的圖，或明確保留其他執行路徑；結果須正確，額外拷貝及記憶體成本需可量測。

已有部分 runtime 支援；本題為 AOT 選擇邏輯，須先與維護者確認剩餘範圍。

08. (build operator) 用模型需求縮小 delegate kernel 建置範圍

原始議題 ↗ 模型 metadata 討論 ↗ XNNPACK 建置 ↗

問題釐清

議題討論 selective build 如何延伸到 delegate 內部：即使模型只用 int8，也可能連入其他精度的 kernel。這與一般 portable 運算子裁剪不同。

可能解法

討論提出由 preprocess 輸出建置 metadata，或解析 delegate blob；前者較直接。仍需 XNNPACK 等相依庫支援，方案尚未定案。

應用場景

在儲存空間有限的裝置上，編譯只服務特定模型的 runtime；需先選定 backend 和可比較的二進位大小基準。

專有名詞介紹

selective build：只編入需要的功能。delegate：接手一段圖的 backend。metadata：描述模型需求的附加資料。

08. (build operator) 用模型需求縮小 delegate kernel 建置範圍

原始議題 ↗ 模型 metadata 討論 ↗ XNNPACK 建置 ↗

重點功能

依模型實際需要的 delegate 運算或精度，裁掉不需要的 kernel；先以討論中的 XNNPACK 能力確認可行範圍。

Input

模型 preprocess 所能提供的需求資訊、backend 建置設定及相依庫能力；metadata 格式待釐清。

Output

仍可正確載入並執行指定模型、且大小可比較的程式庫；尚未承諾縮減比例或跨 backend 的統一介面。

屬架構協調題；現有 ROOT_OPS 改名工作不等於 delegate 內部裁剪。

09. (quantization) 釐清 Arm 量化前後的數值偏差來源

原始議題 ↗ 真實校準資料結果 ↗ 敏感度工具 ↗

問題釐清

回報比較 FP、分解、量化與 TOSA 的輸出：DeiT-tiny 的量化誤差受校準資料影響；LLaMA 在量化前的分解階段就已有偏差，兩者須分開追查。

可能解法

候選路徑：在現版重建逐階段比較，控制權重與校準資料；可參考已合併的量化敏感度工具，但工具本身不是本題已修好的證據。

應用場景

驗證 Arm／TOSA INT8 模型數值品質的人。作者用 tosa_reference_model，並非已驗證所有實體 NPU；LLaMA 使用隨機初始化權重。

專有名詞介紹

PTQ 校準：估計量化範圍。FQ：模擬量化數值的圖。TOSA：運算子規格；cosine：比較向量方向的指標。

偏調查型；100 張驗證圖的 FP 93%、FQ／TOSA 87% 只是作者的小樣本結果。

09. (quantization) 釐清 Arm 量化前後的數值偏差來源

原始議題 ↗ 真實校準資料結果 ↗ 敏感度工具 ↗

修正前

歷史回報中，LLaMA 在 transform_for_annotation 後已偏離 FP；DeiT 用真實校準資料後改善，但各階段仍非逐元素相同，根因未定。

修正後（預期）

在固定版本與資料下，釐清分解是否保持應有語義、量化到 TOSA 的誤差是否符合規格；門檻待釐清，不能要求 INT8 與 FP 完全相同。

偏調查型；100 張驗證圖的 FP 93%、FQ／TOSA 87% 只是作者的小樣本結果。

10. (build operator) 釐清並補 _linalg_solve_ex 的複數支援

原始議題 ↗ ATen schema ↗

問題釐清

議題要求 _linalg_solve_ex 的複數 dtype 與測試；目前 portable／ATen kernel 清單未列此運算，需先確認預期是新增 kernel 還是採分解路徑。

可能解法

候選路徑：先定義線性方程求解與錯誤狀態契約，再評估可用實作及註冊方式。這是較大工作，不宜當成只補一個 dtype。

應用場景

需要在 ExecuTorch 執行複數線性方程求解的模型作者；議題沒有硬體、矩陣大小或數值門檻，切入前須釐清。

專有名詞介紹

LU：把矩陣分解以協助求解。pivots：記錄交換位置。info：回報求解狀態；複數包含實部與虛部。

10. (build operator) 釐清並補 _linalg_solve_ex 的複數支援

原始議題 ↗ ATen schema ↗

重點功能

為 _linalg_solve_ex 提供約定範圍的複數支援與測試；實作位置、dtype 集合及矩陣條件待確認。

Input

矩陣 A、右側張量 B，以及 left、check_errors 選項；依 ATen schema，具體 shape 和 batch 規則待核對。

Output

ATen 介面回傳 result、LU、pivots、info 四個張量；須定義數值誤差、奇異矩陣及錯誤回報的驗收條件。