本週 10 個候選議題

8 個 build operator、2 個 quantization；依需求明確度與可切入範圍排序。候選尚未選定。

01 (build operator) • feat • issue 18104 • 第 2、3 頁
讓多模型共用 selective operator build

02 (build operator) • bug • issue 7984 • 第 4、5 頁
讓 custom kernel 範例進入 CMake 測試

03 (build operator) • feat • issue 11327 • 第 6、7 頁
補齊 col2im.out portable kernel

04 (build operator) • feat • issue 11324 • 第 8、9 頁
補齊 adaptive_avg_pool1d.out

05 (build operator) • feat • issue 11322 • 第 10、11 頁
補齊 _adaptive_avg_pool3d.out

06 (build operator) • feat • issue 11334 • 第 12、13 頁
補齊 avg_pool2d 的輸入梯度 kernel

07 (build operator) • feat • issue 11333 • 第 14、15 頁
補齊自適應 2D 池化的反向 kernel

08 (build operator) • feat • issue 11335 • 第 16、17 頁
補齊 embedding_dense_backward.out

09 (quantization) • feat • issue 16042 • 第 18、19 頁
擴充 Cortex-M 的 Int16 算子覆蓋

10 (quantization) • feat • issue 16043 • 第 20、21 頁
建立 Cortex-M packed int4 權重路徑

01. (build operator) 讓多模型共用 selective operator build

原始議題 ↗ 維護者意見 ↗

問題釐清

同一個 runtime 要執行多個模型時，使用者目前需在外部合併各模型的 operator YAML。議題要求直接接受多個模型或 YAML，或提供正式建置流程；維護者支持以 PTE 清單作為輸入。

可能解法

建議先確認 CMake 參數如何傳遞模型清單，再合併、去重 operator 集合並驗證所有模型。這是待驗證方案；外部合併 YAML 已是回報者使用的替代方式。

應用場景

需要在同一程式部署多個模型、又希望裁減算子庫的開發者。議題未限定硬體；先以 portable CPU 驗證建置流程較容易界定範圍。

專有名詞介紹

Selective build：只編入模型需要的算子。PTE：ExecuTorch 匯出的模型程式。YAML：描述所需算子的設定檔。

未指派；未查得對應開啟修復 PR。方案待用戶選定後驗證。

01. (build operator) 讓多模型共用 selective operator build

原始議題 ↗ 維護者意見 ↗

重點功能

用同一個選擇性建置流程，產生可執行多個模型的算子庫。介面實作或正式文件流程均為原議題接受的方向。

Input

多個 PTE 模型或各模型的 operator YAML。清單語法及混用規則待釐清。

Output

涵蓋所有輸入模型所需算子的建置結果，讓它們可共用一個 runtime。

未指派；未查得對應開啟修復 PR。方案待用戶選定後驗證。

02. (build operator) 讓 custom kernel 範例進入 CMake 測試

原始議題 ↗ 已合併的局部修正 ↗

問題釐清

custom_kernel_example 只有 Buck2 建置設定，CMake 與公開 CI 未涵蓋。這是自訂算子的建置整合缺口，可能漏掉範例退化；目前 CMake 測試清單仍未見此範例。

可能解法

建議加入 CMake 測試目標，再接到適合的公開 CI。既有 PR 7985 已修正範例的 dtype 巨集，但只以內部 Buck2 驗證，沒有完成本議題要求的建置覆蓋。

應用場景

透過範例學習自訂 CPU kernel、使用 CMake 建置的開發者。硬體不限定；原作者留言表示沒有計畫自行處理。

專有名詞介紹

Kernel：算子的具體實作。CMake／Buck2：建置工具。CI：提交程式後自動執行的檢查。

未指派；未查得對應開啟修復 PR。方案待用戶選定後驗證。

02. (build operator) 讓 custom kernel 範例進入 CMake 測試

原始議題 ↗ 已合併的局部修正 ↗

修正前

以 CMake 或既有公開 CI 建置、測試時，custom_kernel_example 沒有被納入；範例曾因此漏掉 dtype 巨集問題。

修正後（預期）

相同流程可以建置並測試此範例，錯誤能由公開檢查發現。具體掛接哪個 CI 工作仍待釐清。

未指派；未查得對應開啟修復 PR。方案待用戶選定後驗證。

03. (build operator) 補齊 col2im.out portable kernel

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

問題釐清

議題要求新增 col2im.out；目前 portable/functions.yaml 未列出它。需要此算子的非委派路徑缺少 portable 實作。議題沒有重現案例、指定模型或驗收條件。

可能解法

建議依 ATen schema 實作區塊回填與重疊累加，再加入註冊與測試。這是待驗證方案；dtype、記憶體排列及動態形狀支援範圍須先確認。

應用場景

含影像區塊重組操作的模型是可能場景；原議題未指定實際模型或硬體。可先在 CPU 對照 ATen 結果，不能據此宣稱裝置部署已可用。

專有名詞介紹

col2im：把展開的區塊資料組回影像。out variant：把結果寫入指定輸出張量。Portable kernel：不依賴特定加速器的實作。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

03. (build operator) 補齊 col2im.out portable kernel

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

重點功能

新增可供 ExecuTorch portable 路徑使用的 col2im.out。

Input

依 ATen schema：區塊張量、輸出大小、kernel_size、dilation、padding、stride 及 out。支援 dtype／形狀範圍待釐清。

Output

寫入 out 的重組張量，語意對齊 ATen col2im。誤差門檻與非法輸入行為待釐清。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

04. (build operator) 補齊 adaptive_avg_pool1d.out

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

問題釐清

議題要求一維自適應平均池化的 portable kernel；目前註冊清單未列出此算子。原文僅列實作需求，未提供模型、失敗訊息或支援範圍。

可能解法

建議依輸出長度劃分池化區間，再對照 ATen 測試邊界與累加精度。方案尚未驗證；需要先約定 dtype、形狀及註冊方式。

應用場景

把一維特徵轉成指定長度是可能用途，例如序列特徵處理。這是算子語意推得的場景；原議題未指定應用或裝置。

專有名詞介紹

Adaptive pooling：由目標輸出大小決定池化區間。平均池化：對區間內數值取平均。out：呼叫端提供的輸出張量。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

04. (build operator) 補齊 adaptive_avg_pool1d.out

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

重點功能

提供 adaptive_avg_pool1d.out 的 portable 實作。

Input

依 ATen schema：輸入張量、單一 output_size 與輸出張量。允許的 dtype、批次及動態維度待釐清。

Output

指定長度的平均池化結果，寫入 out。精度與邊界驗收案例待釐清。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

05. (build operator) 補齊 _adaptive_avg_pool3d.out

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

問題釐清

議題要求三維自適應平均池化的 portable kernel；目前 portable 註冊清單未列出它。缺口屬於算子覆蓋，原文沒有具體部署失敗案例。

可能解法

建議依三個輸出維度計算池化區間，對照 ATen 建立測試後補入註冊。尚未實作；低精度累加與動態輸出需求待釐清。

應用場景

處理體積資料或含時間維度特徵的 CPU 路徑是可能用途。應用由算子語意推得，原議題未指定模型、硬體或效能目標。

專有名詞介紹

三維池化：對三個空間／時間維度聚合數值。Adaptive：輸出大小決定區間。ATen：PyTorch 的算子定義與實作層。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

05. (build operator) 補齊 _adaptive_avg_pool3d.out

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

重點功能

提供 _adaptive_avg_pool3d.out 的 portable 實作。

Input

依 ATen schema：輸入張量、三個 output_size 值與 out。dtype、布局與批次限制待釐清。

Output

寫入 out 的三維平均池化結果，各目標維度符合 output_size；數值驗收標準待釐清。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

06. (build operator) 補齊 avg_pool2d 的輸入梯度 kernel

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

問題釐清

議題要求 avg_pool2d_backward.grad_input；目前 portable 註冊清單未見此算子。這是反向算子實作需求，原文未提供訓練圖或重現步驟。

可能解法

建議依前向池化區間分配輸出梯度，累加重疊位置，並以 ATen 驗證 padding 與除數設定。方案待驗證，支援 dtype 與邊界條件待釐清。

應用場景

需要在 portable 路徑執行平均池化反向圖的工作可能受益。原議題未指定裝置端訓練流程，也沒有端到端可用性的證據。

專有名詞介紹

Backward：由輸出梯度計算輸入梯度。grad_input：對輸入張量的梯度。divisor_override：指定平均時使用的除數。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

06. (build operator) 補齊 avg_pool2d 的輸入梯度 kernel

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

重點功能

提供二維平均池化的 portable 反向算子。

Input

ATen schema 接受 grad_output、原輸入、kernel_size、stride、padding、ceil_mode、count_include_pad、divisor_override 與 grad_input。

Output

把輸入梯度寫入 grad_input；結果對齊同參數的 ATen 算子。支援範圍與誤差門檻待釐清。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

07. (build operator) 補齊自適應 2D 池化的反向 kernel

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

問題釐清

議題要求 _adaptive_avg_pool2d_backward.out；目前 portable 有前向 _adaptive_avg_pool2d.out，但未列出這個反向算子。原文未提供其他驗收要求。

可能解法

建議以原輸入與 grad_output 的形狀重建池化區間，再將梯度分配回輸入位置。這是待驗證方案；先確認 ATen 行為及低精度累加需求。

應用場景

需要在 CPU portable 路徑執行自適應池化反向圖的使用者。原議題沒有指定模型或裝置；不可把單一 kernel 支援等同完整訓練支援。

專有名詞介紹

自適應池化：依目標大小劃分區間。grad_output：輸出端傳回的梯度。反向算子：計算這些梯度對原輸入的影響。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

07. (build operator) 補齊自適應 2D 池化的反向 kernel

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

重點功能

提供 _adaptive_avg_pool2d_backward.out 的 portable 實作。

Input

依 ATen schema：grad_output、原輸入 self 與 out。dtype、布局及動態形狀範圍待釐清。

Output

將對原輸入的梯度寫入 out，對齊 ATen 的反向計算；驗收案例待釐清。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

08. (build operator) 補齊 embedding_dense_backward.out

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

問題釐清

議題要求 embedding_dense_backward.out；目前 portable 註冊清單未列出它。這是 embedding 的反向計算缺口，原文沒有模型、實測數字或驗收案例。

可能解法

建議按 indices 將梯度累加到對應 embedding 列，依 ATen 處理 padding_idx 與頻率縮放。方案未驗證；索引檢查與支援 dtype 須先確認。

應用場景

需要計算 embedding 權重梯度的 portable 反向圖是可能場景。原議題未指明裝置端訓練系統或硬體，尚需確認實際匯出流程。

專有名詞介紹

Embedding：把索引對應到向量。Dense gradient：包含所有權重列的完整梯度張量。頻率縮放：依索引出現次數調整梯度。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

08. (build operator) 補齊 embedding_dense_backward.out

原始議題 ↗ ATen schema ↗ portable 註冊 ↗

重點功能

提供 embedding_dense_backward.out 的 portable 實作。

Input

ATen schema 接受 grad_output、indices、num_weights、padding_idx、scale_grad_by_freq；out variant 另接受輸出張量。

Output

完整 embedding 權重梯度寫入 out，語意對齊 ATen。支援 dtype、索引型別與誤差門檻待釐清。

未指派；未查得對應開啟修復 PR。需求簡短，驗收範圍待釐清。

09. (quantization) 擴充 Cortex-M 的 Int16 算子覆蓋

原始議題 ↗ 設定介面依賴 ↗ 現行量化器 ↗

問題釐清

議題要求為 CMSIS-NN 已支援的算子補齊 Int16 量化、C++ kernel 與 passes。現行 quantizer 已接受 per_tensor_config，並提到 quantized_div 的 Int16 支援；剩餘缺口須逐算子盤點。

可能解法

建議先列 CMSIS-NN 支援與現行覆蓋差異，再逐一補足量化設定、轉換及 kernel。依賴議題 16040 仍開啟且有人負責，須先協調介面，不能沿用「完全不支援 Int16」的舊假設。

應用場景

以 Cortex-M 微控制器部署量化模型、需要 Int16 activation 的使用者。實際 CMSIS-NN 版本、板卡與量測條件仍待確認。

專有名詞介紹

Int16：16 位元整數表示。CMSIS-NN：Arm 微控制器的神經網路 kernel 庫。Pass：把模型圖轉換成後端可執行形式的步驟。

未指派；未查得對應開啟修復 PR。設定介面依賴 16040 須協調。

09. (quantization) 擴充 Cortex-M 的 Int16 算子覆蓋

原始議題 ↗ 設定介面依賴 ↗ 現行量化器 ↗

重點功能

擴充 CMSIS-NN 支援範圍內的 Int16 算子覆蓋，銜接量化設定與執行路徑。

Input

需要 Int16 的模型算子與量化設定。具體算子清單、權重型別及硬體配置待釐清。

Output

受支援算子可經 Cortex-M 轉換並以相符 Int16 kernel 執行；數值驗收與效能目標待釐清。

未指派；未查得對應開啟修復 PR。設定介面依賴 16040 須協調。

10. (quantization) 建立 Cortex-M packed int4 權重路徑

原始議題 ↗ 設定介面依賴 ↗

問題釐清

議題要求在 CMSIS-NN 支援的算子中加入 packed int4，範圍涵蓋 quantizer、C++ kernel 與 passes；原文另指出 lowering 可能需要額外權重整理。完整格式與算子清單尚未定義。

可能解法

建議先確認 CMSIS-NN 要求的權重打包順序，再檢查量化、lowering 與 kernel 是否一致。這是待驗證方案；先與設定介面議題 16040 的負責人協調。

應用場景

在 Cortex-M 上部署、希望以 4 位元權重節省儲存空間的模型。原議題未指定板卡、效能或準確率目標；這些仍是驗收前提。

專有名詞介紹

Packed int4：把兩個 4 位元值放進一個位元組。Lowering：把通用算子轉成後端表示。權重整理：配合 kernel 所需順序重排資料。

未指派；未查得對應開啟修復 PR。設定介面依賴 16040 須協調。

10. (quantization) 建立 Cortex-M packed int4 權重路徑

原始議題 ↗ 設定介面依賴 ↗

重點功能

為 CMSIS-NN 已支援的算子提供 packed int4 量化與執行路徑。

Input

模型權重及相應量化設定。支援算子、activation 型別與 int4 打包格式待釐清。

Output

可由對應 Cortex-M kernel 正確讀取並執行的 packed int4 模型；準確率與記憶體驗收條件待釐清。

未指派；未查得對應開啟修復 PR。設定介面依賴 16040 須協調。