avg_pool1d，占整個模型多少時間？

Qwen/Qwen2-Audio-7B-Instruct

1

每次一段音訊

batch size = 1

32

固定新 token 數

greedy decoding

150

正式請求數

三種長度，各 50 次

以模型實際呼叫的 C++ kernel 耗時，衡量完整推論與 audio encoder 中的占比。

同一顆核心，同一套設定。

硬體與執行

Intel Core i7-14700K

固定 logical CPU 2（P-core；同核 sibling 3）
PyTorch intra-op / inter-op、BLAS / OpenMP 均為 1

C++ KERNEL

GCC / g++ 12.2.0

-O3 -DNDEBUG -march=native
編譯原始 op_avg_pool1d.cpp，模型直接呼叫

模型與權重

預訓練權重，全 FP32

Qwen2-Audio-7B-Instruct · CPU
無量化；PyTorch 2.14.0+cpu / Transformers 5.0.0rc1

GCC 與編譯旗標指本次 C++ kernel；其餘模型使用既有 PyTorch CPU 套件（SDPA）。

音訊長度不同，pooling shape 相同。

120 Hz 合成純音．振幅 0.2．16 kHz．模擬男性基頻，非真人語音

音訊長度	取樣點數	pooling 輸入 → 輸出	有效音訊 token
5 秒	80,000	[1,1280,1500] → [1,1280,750]	125
15 秒	240,000	[1,1280,1500] → [1,1280,750]	375
30 秒	480,000	[1,1280,1500] → [1,1280,750]	750

> 固定提示：**Describe the sound.**

前處理統一補至 30 秒／3000 mel frames；有效音訊 token 數仍影響文字 prefill。

每個請求，量到同一條推論路徑。

AUDIO ENCODER

音訊特徵編碼

實際 C++ avg_pool1d

投影／整合＋prefill
產出第 1 個 token

續解碼 31 步
合計 32 個新 token

完整模型計時：一次 generate 呼叫（包含 audio encoder）

每組 3 次暖機＋50 次正式量測

每次重新開始請求與 KV cache。
batch 1、greedy；關閉 EOS 提前停止。

同批累計時間相除

Σ kernel ÷ Σ 完整模型
Σ kernel ÷ Σ audio encoder

不計載入、音訊生成與前處理。kernel 計時不含 layout 搬移與包裝；encoder／模型計時包含。
p50／p95 分別呈現；占比不是 p50 相除。每次 encoder 與 kernel 各呼叫一次。

以同一批推論，比較 latency 與占比。

時間欄位：上列 p50，下列 p95；占比使用累計耗時。

音訊 長度	avg_pool1d µs	完整模型 ms	Pooling 占完整模型	Audio encoder ms	Pooling 占 encoder
5 秒	1,526.96 2,004.21	62,339.07 66,003.39	0.002702%	17,509.61 18,310.90	0.009592%
15 秒	1,587.62 1,801.82	84,237.42 90,911.16	0.001938%	16,566.39 17,928.55	0.009833%
30 秒	1,473.20 1,516.63	114,928.44 115,253.94	0.001288%	15,387.72 15,506.54	0.009621%

每列 n = 50（另有暖機 3 次）；p95 採線性插值。原始逐次時間與呼叫驗證保留於附件資料。

用占比判斷優化的影響範圍。

0.001288% — 0.002702%

三種音訊長度下，pooling 占完整模型的實測比例。

固定 shape，不等於固定模型成本

pooling 處理相同張量大小；
有效音訊 token 數與文字 prefill 長度不同。

這是指定設定下的量測

120 Hz 純音、FP32、單一 P-core、32 token。
不直接代表真實語音、多執行緒或量化效能。
共享主機；30 秒組中斷後完整重測。
模型耗時包含可能的換頁等待。

來源：Qwen2-Audio 預訓練模型 · 實測 kernel 原始碼
模型 revision 0a095220c30b · kernel revision b63d8204c90f · 原始數據見 results.md / requests.jsonl