01 / 固定環境

EmbeddingBag 記憶體需求比較

比較主要 tensor 配置量（GB），並保留整批執行耗時（µs）

PROCESSOR

Intel Core i7-14700K

單執行緒 · 固定 P-core（CPU 8）

COMPILER

GCC / g++ 12.2.0

算子編譯：-O3 -DNDEBUG -march=native

MODEL

EmbeddingBag(50000, 128)

FP32 · mean / sum / max

KERNEL

op_embedding_bag.cpp

對照組：相同權重、相同輸入
Embedding → 對應的 mean / sum / max

> 完整 N 人批次；同機有其他 CPU benchmark，結果非獨占測試。

02 / 輸入

100 筆觀看紀錄 → 128 維用戶向量

每次 kernel 呼叫處理完整 N 位用戶（單一批次）

50,000
影片 ID 選項

→

100
每人觀看紀錄

→

128
輸出向量維度

每批用戶數 N	影片 ID 數	輸出 shape	拆開版中間 tensor
10K	1,000,000	[10000, 128]	0.512 GB
100K	10,000,000	[100000, 128]	5.12 GB
1M	100,000,000	[1000000, 128]	51.2 GB

權重與 ID 固定種子 42；ID 均勻抽樣、允許重複。這是合成工作負載，不含完整推薦流程。

03 / 測量方式

每組暖機 3 次，完整批次測量 5 次

01

預先準備

輸入與 buffer 預先配置
資料生成與配置不計時

02

暖機 3 次

每次均為完整 N 人批次
可執行組分別暖機

03

正式測量 5 次

每次處理完整 N 人批次
可比較組交替實作順序

記憶體口徑：GB（計算值）

權重＋輸入＋輸出＋必要中間／輔助 tensor

各方法單獨加總；1 GB = 10^9 bytes。不含 allocator／runtime 開銷，非 RSS 實測。

每組 p50 / p95 僅由 5 筆完整批次計時估計；p95 樣本有限。
資料生成、配置與正確性檢查不計時；拆開版包含 embedding ＋ reduction。

04 / 記憶體與耗時

mode = mean

GB：主要 tensor 配置量（計算值）｜µs：整批耗時（實測）

每批人數 N	EmbeddingBag 記憶體（GB）	拆開版本 記憶體（GB）	EmbeddingBag p50 / p95（µs）	拆開版本合計 p50 / p95（µs）
10K	0.047	0.551	154,015 / 165,527	122,983 / 145,662
100K	0.239	5.277	1,665,582 / 1,710,533	1,369,148 / 1,398,455
1M	2.162	52.538	16,826,143 / 16,918,738	記憶體不足，未測

1M 人同批：EmbeddingBag 2.162 GB；拆開版 52.538 GB

1M 拆開版未執行：GB 依 shape 與 dtype 計算，耗時維持未測。容量不等於程序 RSS。
每列皆為完整 N 人批次；每組僅 5 筆計時，且同機有其他 CPU 工作。

05 / 記憶體與耗時

mode = sum

GB：主要 tensor 配置量（計算值）｜µs：整批耗時（實測）

每批人數 N	EmbeddingBag 記憶體（GB）	拆開版本 記憶體（GB）	EmbeddingBag p50 / p95（µs）	拆開版本合計 p50 / p95（µs）
10K	0.039	0.551	159,443 / 174,551	121,994 / 125,231
100K	0.159	5.277	1,648,816 / 1,668,183	1,210,154 / 1,246,282
1M	1.362	52.538	17,324,329 / 17,515,396	記憶體不足，未測

1M 人同批：EmbeddingBag 1.362 GB；拆開版 52.538 GB

1M 拆開版未執行：GB 依 shape 與 dtype 計算，耗時維持未測。容量不等於程序 RSS。
每列皆為完整 N 人批次；每組僅 5 筆計時，且同機有其他 CPU 工作。

06 / 記憶體與耗時

mode = max

GB：主要 tensor 配置量（計算值）｜µs：整批耗時（實測）

每批人數 N	EmbeddingBag 記憶體（GB）	拆開版本 記憶體（GB）	EmbeddingBag p50 / p95（µs）	拆開版本合計 p50 / p95（µs）
10K	0.057	0.561	225,001 / 278,815	202,557 / 209,554
100K	0.341	5.379	2,366,769 / 2,370,542	2,188,595 / 2,277,909
1M	3.178	53.562	24,291,602 / 24,818,624	記憶體不足，未測

1M 人同批：EmbeddingBag 3.178 GB；拆開版 53.562 GB

1M 拆開版未執行：GB 依 shape 與 dtype 計算，耗時維持未測。容量不等於程序 RSS。
每列皆為完整 N 人批次；每組僅 5 筆計時，且同機有其他 CPU 工作。