ExecuTorch 候選議題

10

閱讀問題，評估解法，
選定後再開始開發。

保留每題的問題釐清、可能解法與來源。
尚未選題；以下方向未在本機重現，也不代表已完成修正。

從一個問題開始。

01 (operator)
Cortex-M depthwise convolution 缺少輸入 layout 檢查

02 (runtime)
Python Module 對 device output 配置了 host memory

03 (backend)
Vulkan 對不支援 dtype 缺少 partition fallback

04 (export)
新版 ultralytics 的 YOLO26 strict export 仍失敗

05 (inference)
補齊 Arm streaming wakeword 匯出與連續幀測試

06 (perf)
評估 XNNPACK workspace 與 ET activation memory 共用

07 (memory)
支援沒有固定上界的動態 tensor memory

08 (operator)
補齊 while_loop 的 lowering 與 emitter 支援

09 (export)
讓隱含 dim-order 轉換在 portable graph 中一致表達

10 (ci)
評估依賴更新流程與受控的排程設定

1. (operator) Cortex-M depthwise convolution 缺少輸入 layout 檢查

閱讀原始議題 ↗ 來源更新 2026-10-14T14:58:09Z

問題釐清

channels-first 輸入會被替換成只接受 channels-last 的 Cortex-M kernel，導致執行時報錯。原文提供 contiguous 輸入與 mean pooling 後接 depthwise convolution 的兩個案例；fake implementation 的形狀推導沒有阻止不支援的 layout。議題目前沒有留言或指派者。

可能解法

先用原文兩個案例確認 lowering 與 runtime 的 layout；依作者建議，在不支援時保留原 operator，或插入明確 layout conversion。同步檢查 fake implementation 的限制，加入轉換前後數值與 layout 回歸測試；完整執行需要 Cortex-M 測試環境。

2. (runtime) Python Module 對 device output 配置了 host memory

閱讀原始議題 ↗ 來源更新 2026-10-07T21:52:36Z

問題釐清

PyModule::allocate_output_tensors 對未規劃的輸出一律配置 host bytes，即使輸出標記為 CUDA。這可能被 delegate 拒絕，或在後續 GPU 複製時出錯。既有 Method 修正已合併，但其描述明確將 Module 路徑留給本題；目前無指派者。

可能解法

參照 Method 的 device allocator 路徑，讓 Module 依輸出 device 配置 buffer，並讓回傳 tensor 正確持有生命週期。測試連續執行時舊輸出仍有效、device/CPU/零長度輸出與配置失敗情境；CUDA 行為需在實際 GPU 驗證。

3. (backend) Vulkan 對不支援 dtype 缺少 partition fallback

閱讀原始議題 ↗ 來源更新 2026-09-18T20:36:43Z

問題釐清

原始案例因 float64 在 Vulkan serialization 被拒絕而無法匯出；最新留言指出 float64、int16 已可使用，剩下 uint16、uint32 執行失敗及 uint64 序列化失敗。應重新確認目前支援矩陣，避免照舊清單把已支援 dtype 排除。

可能解法

在 partitioner 判斷輸入與輸出的 dtype 能力，對不支援的節點保留 CPU fallback，並確認 portable kernel 本身是否支援。以 unsigned dtype 測試匯出、delegate 邊界及數值一致性，也涵蓋已支援 dtype 的不退步測試。

4. (export) 新版 ultralytics 的 YOLO26 strict export 仍失敗

閱讀原始議題 ↗ 來源更新 2026-10-06T18:05:01Z

問題釐清

此題原本含兩個問題。layout 修正已合併，處理 8.4.133–8.4.139 的 channels-last 權重；剩餘範圍是 8.4.140 以後 strict export 的 PendingUnbackedSymbolNotFound。既有 pin 讓 CI 避開問題，不等於新版已支援。

可能解法

以目前仍能重現的 ultralytics 版本縮小 unbacked symbol 的來源，檢查模型 wrapper 與匯出分支，先完成 strict export 與 portable 數值比對再提高 pin。不要重做已合併的 layout 修正；需下載模型權重並建立版本對照。

5. (inference) 補齊 Arm streaming wakeword 匯出與連續幀測試

閱讀原始議題 ↗ 來源更新 2026-10-05T22:04:06Z

問題釐清

需求是將 portable streaming wakeword 延伸到 TOSA FP/INT 與 Ethos-U55/U85。已合併的模型 PR只加入模型、註冊與 eager 測試，明確未涵蓋 export/backend/runner；模型保留跨幀狀態，30 幀後輸出才有效。目前無指派者或留言。

可能解法

先確認 portable export 前置工作是否就緒，再以 successive frames 與 reset/replay 建立 TOSA reference 比對，之後驗證 U55/U85 FVP。測試需檢查跨幀 buffer 狀態與量化誤差；FVP、TOSA 工具鏈及前置 export 是環境／依賴條件。

6. (perf) 評估 XNNPACK workspace 與 ET activation memory 共用

閱讀原始議題 ↗ 來源更新 2026-10-14T21:31:09Z

問題釐清

DelegateScratchSpec已合併，因此不能再把此題描述成完全沒有 scratch API。最新維護者留言表示 XNNPACK 仍使用 malloc，原本的整體記憶體需求尚未完全解決；也已有社群成員詢問量測切入點，正式開發前需釐清剩餘範圍。

可能解法

先選含 graph break 的模型量測 ET arena 與 XNNPACK workspace 的峰值及生命週期，再評估靜態 shape 能否預先取得 workspace 大小並使用既有 scratch API。先以量測與小型概念驗證決定是否值得整合，不承諾直接完成跨 delegate 的通用記憶體規劃。

7. (memory) 支援沒有固定上界的動態 tensor memory

閱讀原始議題 ↗ 來源更新 2026-10-06T16:27:55Z

問題釐清

原文希望避免所有 tensor 都依最大 shape 預留空間，並支援輸入尺寸範圍大或難以給定上界的模型。需求包含 activation buffer 重用、避免增加受限裝置 runtime 體積，以及資料相依 shape。最新留言仍在詢問進度，這是範圍較大的架構題。

可能解法

先驗證目前 main 的既有動態能力，將剩餘需求拆成最小案例，評估序列化 lifetime metadata、buffer 重新配置及 relocation。以 build option 隔離額外 runtime 成本，比較峰值記憶體與延遲；本題適合分階段研究，不宜承諾一週完成。

8. (operator) 補齊 while_loop 的 lowering 與 emitter 支援

閱讀原始議題 ↗ 來源更新 2026-09-18T20:13:22Z

問題釐清

題名同時提到 while_loop 與 scan，但 scan 支援已合併，不能重做。討論中的 while 前段 pass 修正也已存在；最新留言指出仍在 emitter 被拒絕，測試還預期 Unsupported control flow operator。記憶體規劃與迴圈 shape 邊界需另外釐清。

可能解法

先以最小 while_loop 驗證失敗階段，再參照 cond/map/scan 的 emission，評估以現有 primitive 與 jump 表達迴圈。補零次／多次迭代、carry tensor、shape 上界與輸出數值測試，並獨立檢查迴圈生命週期的 memory planning；不要先假定需要擴充 runtime。

9. (export) 讓隱含 dim-order 轉換在 portable graph 中一致表達

閱讀原始議題 ↗ 來源更新 2026-10-05T20:59:31Z

問題釐清

PyTorch 的 Linear、reduction 或 convolution 可能隱含轉 layout，但匯出的節點 metadata 改變後，graph 不一定有對應 copy，portable kernel 因混合 dim order 失敗。近期討論指出局部插入 copy 可能造成錯值或把問題移到下游；已有其他人提出研究與承接意願，本題列為需協調的候選。

可能解法

先用 reduction 加 elementwise 與 channels-last Linear 的小案例重現，檢查輸入、輸出 metadata/spec 與實際 storage 的一致性。評估在 lowering 中同時插入 conversion 與傳播 output dim order，而非只對單一 kernel 打補丁。加入混合 layout 多算子鏈的數值回歸測試；開始前需由用戶確認是否與既有工作重疊。

10. (ci) 評估依賴更新流程與受控的排程設定

閱讀原始議題 ↗ 來源更新 2026-08-10T19:18:23Z

問題釐清

這是一項提案而非已證實的 runtime bug：作者建議每月更新非 breaking dependencies，並考慮套件發布等待期及 CI 觸發方式。目前沒有留言或關聯 PR；是否採用第三方 Action、哪些 pin 可自動更新，以及維護者是否接受，尚未定案。

可能解法

先盤點相依與版本 pin 的用途，提出最小設定草稿，評估現有工具、權限、可重現性與更新分組；只在個人 fork 驗證設定。不得設定社群 secrets、啟用社群 workflow 或自動發送社群 PR；是否採用及正式送出由用戶與維護者決定。