查看處理進度 ↗

本週 10 個候選議題

8 個 quantization、2 個 speculative decoding；與上週零重複。EAGLE-3 與 LPBQ 為協作／驗收候選，先確認既有負責人的進度。此批尚未選定。

01 (speculative decoding) · feat · issue 20431 · 第 2、3 頁
釐清推測解碼的 KV commit／rollback 契約

02 (speculative decoding) · feat · issue 19784 · 第 4、5 頁
檢查 EAGLE-3 的驗收與既有 runner 整合缺口

03 (quantization) · bug · issue 24125 · 第 6、7 頁
定位 QNN 16a8w 的 gather 輸出讀值錯誤

04 (quantization) · feat · issue 22431 · 第 8、9 頁
補 Vulkan INT8 weight 的 per-token activation 路徑

05 (quantization) · feat · issue 13476 · 第 10、11 頁
釐清並補齊 Vulkan 動態 INT8 convolution

06 (quantization) · feat · issue 13063 · 第 12、13 頁
對齊 NXP Conv／MatMul 與 activation 的量化邊界

07 (quantization) · bug · issue 12341 · 第 14、15 頁
重新定位 MobileBert／Albert 的 XNNPACK 量化阻塞

08 (quantization) · bug · issue 19132 · 第 16、17 頁
查核 QNN 混合精度的 partition 與 FP16 邊界

09 (quantization) · bug · issue 23922 · 第 18、19 頁
協作定位 QNN LPBQ stride-2 convolution＋ReLU 失敗

10 (quantization) · feat · issue 9515 · 第 20、21 頁
補齊量化到品質驗證的端到端文件缺口

01. (speculative decoding) 釐清推測解碼的 KV commit／rollback 契約

原始議題 ↗

問題釐清

RFC 希望同一份模型能切換一般解碼與 tree／speculative decoding。候選 token 被拒絕後，KV 狀態必須保持正確；留言另提出 ring-buffer eviction、每層 head 數不同，以及 export-time 靜態 KV 量化的需求。

可能解法

建議先縮小到 SeqCache／TreeCache 的介面與正確性案例，驗證 propose、commit、分支遮罩與拒絕後續接。靜態 KV 量化如何參與 runtime 控制仍待 RFC 討論，不直接承諾整套跨 backend 實作。

應用場景

需要 EAGLE 類推測解碼、prefix 分支或 agent 工作流的桌面端 runner；RFC 提及 MLX、XNNPACK 與 Vulkan。切入點是契約與測試，硬體實作另議。

專有名詞介紹

KV cache：保留先前 token 的注意力資料。Commit／rollback：保留接受的候選、撤回被拒絕候選的狀態。Tree mask：限定每個分支可讀取的歷史。

01. (speculative decoding) 釐清推測解碼的 KV commit／rollback 契約

原始議題 ↗

重點功能

定義可支援一般及 tree／speculative decoding 的 cache 契約；先處理一個可驗證的子範圍。

Input

模型架構資訊、token 位置、候選樹與接受的路徑；靜態 KV 量化參數的傳遞方式待釐清。

Output

可核對接受／拒絕後狀態的介面與測試，不把 RFC 文字當作已完成的 runtime。

02. (speculative decoding) 檢查 EAGLE-3 的驗收與既有 runner 整合缺口

原始議題 ↗ 關閉的相關 PR ↗

問題釐清

RFC 規劃在 TextLLMRunner 下加入 EAGLE-3，涵蓋 draft、target verify、接受／拒絕與 KV 正確性。留言曾指向 PR 20157；該 PR 已關閉且未合併，不能據此宣稱整項功能已完成或完全沒有人做。

可能解法

先盤點目前 runner 與其他 speculative PR 的已實作範圍，和原作者確認尚缺的驗收案例。候選切入點是 greedy 等價性、部分／全部接受、拒絕後 KV 與 EOS／token budget；不另開競爭性全功能實作。

應用場景

RFC 的 P0 指向 Gemma4、batch size 1、固定 chain 長度與 CUDA／MLX。這是協作與驗收候選，需確認可用模型、硬體及原作者意願後再開發。

專有名詞介紹

EAGLE-3：利用較小 draft 模型提案，再由 target 驗證。Rejection sampling：修正提案分布的接受／拒絕取樣。Lossless：輸出符合 target 的解碼語義。

02. (speculative decoding) 檢查 EAGLE-3 的驗收與既有 runner 整合缺口

原始議題 ↗ 關閉的相關 PR ↗

重點功能

沿用既有 runner 的 tokenizer、prefill、callback 與統計，確認推測生成策略尚缺的可驗收子項。

Input

Target／draft PTE、draft 機率、所需 hidden states、KV 狀態與生成參數。

Output

經協調後的缺口清單與 target 語義一致性測試；不把曾關閉的 PR 當作可直接接手的任務。

協作／驗收候選；先查既有進度。PR 20157 closed、merged=false；不推薦重做整套。

03. (quantization) 定位 QNN 16a8w 的 gather 輸出讀值錯誤

原始議題 ↗

問題釐清

回報的 16a8w 圖中，cos／sin 經 gather 後供兩個 RoPE 使用；只通往 graph output 的最後 consumer 讀值錯誤。回報 output 2 的相對誤差約 0.77，host QDQ 約 0.0017；FP16 與直接傳入 cos／sin 不受影響。

可能解法

建議用原有最小圖比較 gather、consumer 與 graph output 的 lowering／記憶體生命週期。先在目前 main 重現，再定位 QNN delegate／SDK 邊界；記憶體別名或生命週期目前只是調查方向。

應用場景

SM8850／Galaxy S26 Ultra、QAIRT 2.47 的量化 TTS／RoPE 圖。回報基於 1.4.1 fork，尚未查核 main；裝置驗證是必要成本。

專有名詞介紹

16a8w：16-bit activation、8-bit weight。Gather：按索引取表格列。RoPE：旋轉位置編碼。QDQ：量化再反量化的參考圖。

未指派、無留言；未查得 timeline 修復 PR。須先在 main 與裝置重現。

03. (quantization) 定位 QNN 16a8w 的 gather 輸出讀值錯誤

原始議題 ↗

修正前

相同 gather 結果的最後 consumer 只輸出到圖外時，量化輸出出現大誤差。

修正後（預期）

同一最小圖各個輸出應與參考值落在已定義的量化誤差範圍內。

未指派、無留言；未查得 timeline 修復 PR。須先在 main 與裝置重現。

04. (quantization) 補 Vulkan INT8 weight 的 per-token activation 路徑

原始議題 ↗ 已合併的文字修正 ↗

問題釐清

回報指出 Vulkan 動態 activation 量化實際是 per-tensor；Transformer encoder embedding 的精度較 per-token 控制組差。PR 22432 已合併，但只修正註解，沒有實作 per-token INT8 weight kernel。

可能解法

建議先定義 per-token activation 與 INT8 weight 的資料契約，再對齊 quantizer、pattern 與 runtime kernel。以 eager／QDQ／delegate 三段比對，避免把註解修正重當成未完成工作。

應用場景

Vulkan 上的句向量與 Transformer encoder；需能跑 Vulkan 的裝置。回報提到 issue 22372 的 scalar／embedding 前置問題，開始前需重新確認其狀態。

專有名詞介紹

Per-tensor：整個輸入共用 scale。Per-token：每列 token 有自己的量化尺度。Cosine similarity：比較兩個 embedding 的方向是否接近。

未指派；PR 22432 僅完成文字修正，功能缺口仍由原 issue 追蹤。

04. (quantization) 補 Vulkan INT8 weight 的 per-token activation 路徑

原始議題 ↗ 已合併的文字修正 ↗

重點功能

支援與 INT8 weight 搭配的 per-token 動態 activation 量化，並建立精度比較。

Input

Transformer activation、INT8 weights、每個 token 的量化參數與測試模型。

Output

一致的 quantizer／kernel 路徑與量化誤差結果；效能提升需另行量測。

未指派；PR 22432 僅完成文字修正，功能缺口仍由原 issue 追蹤。

05. (quantization) 釐清並補齊 Vulkan 動態 INT8 convolution

原始議題 ↗

問題釐清

議題直接要求 Vulkan backend 的動態量化 8-bit convolution，未提供輸入形狀、支援的 convolution 變體或驗收模型。它是功能需求，不能假裝已取得失敗重現。

可能解法

先核對目前 main 的既有 conv／量化 kernel，再確認 activation granularity、weight layout 與支援範圍。若缺口仍在，以單一 convolution 變體開始，補 partition、shader 與數值測試。

應用場景

希望在 Vulkan GPU 上執行量化 CNN 的使用者。需要 Vulkan runtime／GPU；模型與 stride、padding 等組合由需求澄清後決定。

專有名詞介紹

動態量化：執行時依 activation 求量化參數。Convolution：影像模型常用的卷積運算。Shader：GPU 上執行 kernel 的程式。

05. (quantization) 釐清並補齊 Vulkan 動態 INT8 convolution

原始議題 ↗

重點功能

Vulkan backend 的動態 INT8 convolution 支援；具體變體與 granularity 待釐清。

Input

輸入 activation、量化 weights、convolution 參數；精確 dtype／layout 契約待確認。

Output

可委派到 Vulkan 的運算與對應數值測試；不承諾未定義的全面覆蓋。

06. (quantization) 對齊 NXP Conv／MatMul 與 activation 的量化邊界

原始議題 ↗ 相關 HardTanh 修正 ↗

問題釐清

Neutron Quantizer 目前將 activation 分開量化；原議題指出 NPU 可把 Conv／MatMul 與後續 activation 合為一次計算，因此需要 DQ → Conv → Activation → Q 的量化邊界。

可能解法

建議挑一個 activation pattern，對照 annotation 與融合後的圖，確認共享 qparams 的規則並補回歸測試。相關 PR 12893 已修 HardTanh 的一部分設定，不能把它算作整個融合需求已解決。

應用場景

NXP Neutron NPU 的量化 CNN 或含 MatMul 的模型；主機可先驗證圖結構，最終執行仍需相容 backend／裝置。

專有名詞介紹

Qparams：scale、zero point 等量化參數。Fusion：多個運算由同一個 backend 路徑執行。Annotation：在圖中描述量化規則。

未指派；有 NXP 內部追蹤 ID。先確認相關局部修正及 backend 維護者需求。

06. (quantization) 對齊 NXP Conv／MatMul 與 activation 的量化邊界

原始議題 ↗ 相關 HardTanh 修正 ↗

重點功能

依 Conv／MatMul 後接 activation 的模式，產生符合 Neutron 融合語義的量化區段。

Input

包含相鄰 Conv／MatMul 與 activation 的 exported graph、量化設定與校正資料。

Output

正確的 Q／DQ 邊界、量化參數與圖結構測試；裝置精度需另驗證。

未指派；有 NXP 內部追蹤 ID。先確認相關局部修正及 backend 維護者需求。

07. (quantization) 重新定位 MobileBert／Albert 的 XNNPACK 量化阻塞

原始議題 ↗

問題釐清

原議題記錄 MobileBert 與 Albert 的量化 CI 被關閉，留言也回報量化 MobileBert 無法產生 PTE；embedding 被提出為可能方向，但未獲確認。舊版本錯誤不代表目前 main 仍相同。

可能解法

建議先檢查目前 CI 設定，使用標準 export／test 工具確認兩個模型能否量化與執行。僅在問題仍可重現時定位 unsupported pattern／embedding，補測試後再恢復對應 CI。

應用場景

希望把 BERT 類文字編碼器部署到 XNNPACK CPU 的開發者。歷史留言提及 v0.6.0-rc6-android；目前版本適用性是首要查核點。

專有名詞介紹

XNNPACK：CPU 運算 backend。Embedding：將 token index 轉成向量。PTE：ExecuTorch 的部署程式檔。

未指派；留言曾請維護者調查，未查得 timeline 修復 PR。須先驗證時效。

07. (quantization) 重新定位 MobileBert／Albert 的 XNNPACK 量化阻塞

原始議題 ↗

修正前

歷史回報中，兩個模型的量化 CI 停用，量化 MobileBert 匯出受阻；目前 main 待重現。

修正後（預期）

若缺陷仍存在，修正後能用標準流程量化、匯出並執行，並恢復相應測試。

未指派；留言曾請維護者調查，未查得 timeline 修復 PR。須先驗證時效。

08. (quantization) 查核 QNN 混合精度的 partition 與 FP16 邊界

原始議題 ↗

問題釐清

回報在同一 QNN 圖混用量化與 FP16 計算時 graph prepare 失敗。討論進一步聚焦 Qwen3.5 DeltaNet 的 L2-normalize、sigmoid、softplus；CPU fallback 約造成 20 次 graph break。

可能解法

先依維護者建議區分 FP16 activation／quantized weight，與整個 FP16 區段。比較 skip_annotation 分圖與 backend 可支援的 FP16a4w／FP16a8w 路徑；不要承諾 SDK 不支援的同一 partition 混用。

應用場景

Snapdragon 8 Gen 5 上的 Qwen3.5 精度敏感區段。需要 QAIRT／HTP 環境與裝置；應先取得最小 operator 子圖，不直接重做整個模型。

專有名詞介紹

Mixed precision：不同區段使用不同位元精度。Partition：交由同一 delegate 執行的子圖。Graph break：分圖後可能增加資料往返成本。

未指派；維護者仍在釐清 FP16 需求與子圖。方案需配合 SDK 支援範圍。

08. (quantization) 查核 QNN 混合精度的 partition 與 FP16 邊界

原始議題 ↗

修正前

量化與 FP16 敏感運算組合在 graph prepare 出錯，或必須大量切回 CPU。

修正後（預期）

對已確認支援的子圖可正確執行；不支援組合應清楚診斷或合理分圖，並量測精度與成本。

未指派；維護者仍在釐清 FP16 需求與子圖。方案需配合 SDK 支援範圍。

09. (quantization) 協作定位 QNN LPBQ stride-2 convolution＋ReLU 失敗

原始議題 ↗

問題釐清

SM8850 上，16a4w_block 的 stride-2 convolution 後接 ReLU，在 block size 16／32／64 都無法完成 HTP graph prepare，錯誤為 Relu16bParamsPlaceholder。stride 1、去掉 ReLU、改用 per-channel 16a4w 則可通過。

可能解法

這題已有 psiddh 指派，僅建議協作重現與縮小問題。比較 LPBQ pattern、activation 量化參數與 SDK graph prepare；若屬 SDK 缺口，提供精簡案例，不自行宣稱改 Python annotation 就能修好。

應用場景

SM8850／V81、QAIRT 2.47 的 ResNet 類 CNN。原最小案例使用 256→128 channel convolution；需要 SDK 與相容目標驗證。

專有名詞介紹

LPBQ：以 block 表示低精度 weight 的量化方式。Stride 2：降低空間解析度的卷積步幅。HTP graph prepare：SDK 為 NPU 建立可執行圖。

協作候選，已指派 psiddh；未查得 timeline 修復 PR。先對齊負責人，不宣稱可自由接手。

09. (quantization) 協作定位 QNN LPBQ stride-2 convolution＋ReLU 失敗

原始議題 ↗

修正前

上述 stride-2＋ReLU＋LPBQ 組合無法產生 QNN context binary。

修正後（預期）

支援的組合可完成 prepare 並驗證數值；若 SDK 不支援，應提供明確限制或受測替代路徑。

10. (quantization) 補齊量化到品質驗證的端到端文件缺口

原始議題 ↗

問題釐清

議題要求整理 PT2E 的 PTQ／QAT／品質驗證，以及 quantize_ 的 GPTQ／PARQ 研究流程。原文是文件需求，沒有可引用的失敗輸出；需先盤點目前文件已覆蓋哪些內容。

可能解法

建議選一個仍欠缺的可執行流程，沿用官方 CLI／測試工具連接校正、轉換、export 與品質比較，列出版本及 backend 限制。既有文件已完整覆蓋的章節不重寫。

應用場景

第一次在 ExecuTorch 選擇量化策略、比較模型品質的使用者。以有公開可取得輸入與模型的流程為主，避免只有內部資源能重跑。

專有名詞介紹

PTQ：訓練後量化。QAT：訓練時模擬量化。GPTQ／PARQ：不同的進階量化流程。品質驗證：比較量化後與參考模型的結果。

10. (quantization) 補齊量化到品質驗證的端到端文件缺口

原始議題 ↗

重點功能

連接 PT2E PTQ／QAT 與品質驗證，並說明 quantize_ 進階流程的適用性。

Input

已確認的官方工具、模型與資料來源、量化設定及比較指標。

Output

能逐行執行與驗證的量化指南；需先確認缺口，不以自製 harness 取代正式工具。

未指派、無留言或 timeline 修復連結；文件缺口需對照目前 main 確認。