本週 10 個候選議題

9 個 build operator、1 個 quantization；依需求明確度與可切入範圍排序。候選尚未選定。

01 (build operator) • feat • issue 11418 • 第 2、3 頁
補齊 full 的複數 dtype 與測試

02 (build operator) • feat • issue 11419 • 第 4、5 頁
讓 where.self 保留複數分支的值

03 (build operator) • feat • issue 11407 • 第 6、7 頁
補 index_select 的複數匯出與測試

04 (build operator) • feat • issue 11421 • 第 8、9 頁
補 repeat 的複數型別與重複結果測試

05 (build operator) • feat • issue 11337 • 第 10、11 頁
新增 native_layer_norm_backward portable kernel

06 (build operator) • feat • issue 11336 • 第 12、13 頁
新增 native_group_norm_backward portable kernel

07 (build operator) • feat • issue 10726 • 第 14、15 頁
讓 Python runtime 可直接呼叫 kernel

08 (build operator) • feat • issue 14018 • 第 16、17 頁
將 aten 命名的 prim ops 移入 portable

09 (build operator) • feat • issue 16347 • 第 18、19 頁
以量測改善 CMSIS-NN convolution 選擇

10 (quantization) • feat • issue 14221 • 第 20、21 頁
處理 XNNPACK group size 16 的線性量化

01. (build operator) 補齊 full 的複數 dtype 與測試

原始議題 ↗ 現行 kernel ↗ Edge 型別表 ↗

問題釐清

議題要求 full 支援複數。現行 full.out 僅 dispatch 實數與布林，Edge dtype 表也未列複數；模型建立複數常數時仍有支援缺口。

可能解法

待驗證方案：先補複數輸出與 scalar 轉換，再對照 PyTorch 檢查實部、虛部及 dtype。需同步檢查 Edge 規則；複數填充值的 Scalar 表達仍待釐清。

應用場景

適用於以 portable CPU 執行的複數資料處理模型，例如建立訊號運算所需的常數張量。原 issue 未指定硬體或模型。

專有名詞介紹

複數含實部與虛部；dtype 是元素型別。full 依形狀填滿同一數值；out 代表結果寫入呼叫端提供的張量。

未指派；未查得對應修復 PR。需求來自標題，精度與 Scalar 範圍待確認。

01. (build operator) 補齊 full 的複數 dtype 與測試

原始議題 ↗ 現行 kernel ↗ Edge 型別表 ↗

重點功能

讓 full 可產生複數張量，並有對應測試；原議題未指定必要的複數精度範圍，需先確認。

Input

張量形狀、填充值與目標複數 dtype；是否要求複數填充值及所有混合轉型，待釐清。

Output

每個元素符合填充值、形狀與指定 dtype 的張量；預期行為以 PyTorch 對照確認。

未指派；未查得對應修復 PR。需求來自標題，精度與 Scalar 範圍待確認。

02. (build operator) 讓 where.self 保留複數分支的值

原始議題 ↗ 現行 kernel ↗ Edge 型別表 ↗

問題釐清

議題要求 where.self 的複數支援與測試。現行 kernel 的計算型別與兩個資料輸入都限制為實數路徑，複數分支尚未納入。

可能解法

待驗證方案：擴充資料分支的複數 dispatch 與型別提升，保持條件為布林；用 PyTorch 對照選值及 broadcasting，避免只放寬 Edge 規則。

應用場景

適用於 portable CPU 上以遮罩選擇複數資料的流程。原議題未提供模型、硬體或既有失敗輸出。

專有名詞介紹

where 依條件逐元素選值；broadcasting 讓相容形狀對齊；型別提升決定兩個分支共同使用的輸出型別。

02. (build operator) 讓 where.self 保留複數分支的值

原始議題 ↗ 現行 kernel ↗ Edge 型別表 ↗

重點功能

補上 where.self 的複數資料分支支援與測試，條件選值維持既有語意。

Input

布林條件、兩個可對齊形狀的資料張量；必要複數精度與實數／複數混用範圍待確認。

Output

依條件選出的張量，保留選中元素的實部與虛部；形狀與輸出 dtype 對齊 PyTorch。

未指派；未查得對應修復 PR。尚未執行重現或驗收。

03. (build operator) 補 index_select 的複數匯出與測試

原始議題 ↗ 現行 kernel ↗ 測試 TODO ↗

問題釐清

底層 index_select 已按元素位元組數複製，不能直接斷言 kernel 不會處理複數。可確認的缺口是 Edge 型別表未列複數，測試也保留 complex TODO。

可能解法

待驗證方案：先驗證現有複製路徑，再補 Edge dtype 與複數測試；對照重複索引、負軸及空輸出，不預先重寫搬移邏輯。

應用場景

適用於 portable CPU 的複數張量切片與依索引取值。這是既有 operator 的支援與覆蓋擴充，原 issue 未指定硬體。

專有名詞介紹

index_select 沿指定軸選取索引；Int／Long 是索引整數型別；位元組複製可保留實部與虛部，但完整匯出仍須驗證。

未指派；未查得對應修復 PR。已有複製邏輯，剩餘工作含型別與測試驗證。

03. (build operator) 補 index_select 的複數匯出與測試

原始議題 ↗ 現行 kernel ↗ 測試 TODO ↗

重點功能

完成 index_select 的複數支援與測試，涵蓋匯出允許的型別與實際執行。

Input

複數輸入、選取軸及一維整數索引；必要精度與邊界測試清單待確認。

Output

指定索引順序的複數張量；實部、虛部與形狀符合 PyTorch，非法索引仍回報錯誤。

未指派；未查得對應修復 PR。已有複製邏輯，剩餘工作含型別與測試驗證。

04. (build operator) 補 repeat 的複數型別與重複結果測試

原始議題 ↗ 複製實作 ↗ Edge 型別表 ↗

問題釐清

repeat 已依 element_size 搬移資料，未見資料 dtype 的實數 dispatch 限制；但 Edge repeat 型別表未列複數，現有測試也未明列複數案例。

可能解法

待驗證方案：確認既有 repeat_tensor 能保留完整複數，再補匯出型別與測試。驗證零次重複、多軸重複與動態輸出，不把未測路徑描述為已支援。

應用場景

適用於 portable CPU 上需重複複數陣列的資料處理。原議題沒有指定模型或裝置；可從小型 tensor 測試切入。

專有名詞介紹

repeat 將整個張量按各軸次數複製；element_size 是一個元素佔用的位元組數；動態輸出表示執行時調整結果形狀。

未指派；未查得對應修復 PR。底層能力尚待實測，不能只以 issue 開啟判定未實作。

04. (build operator) 補 repeat 的複數型別與重複結果測試

原始議題 ↗ 複製實作 ↗ Edge 型別表 ↗

重點功能

完成 repeat 的複數支援與測試，保留各軸重複的既有語意。

Input

複數張量與各軸的非負重複次數；必要複數精度與動態形狀範圍待確認。

Output

形狀按重複次數擴展、每份複數內容一致的張量；零次重複的結果應符合既有語意。

未指派；未查得對應修復 PR。底層能力尚待實測，不能只以 issue 開啟判定未實作。

05. (build operator) 新增 native_layer_norm_backward portable kernel

原始議題 ↗ portable 註冊 ↗ ATen schema ↗

問題釐清

議題要求實作 native_layer_norm_backward.out。現行 portable 註冊包含前向 LayerNorm，未列 backward；需要反向運算的 CPU 圖仍有 operator 缺口。

可能解法

待驗證方案：依 ATen schema 計算輸入、權重及偏置梯度，按 output_mask 決定需要的結果；先確認 dtype、空張量與輸出 buffer 規則，再補註冊及數值對照。

應用場景

適用於裝置端訓練或需要 LayerNorm 梯度的 portable CPU 流程。這是依算子語意推定的用途；原 issue 沒有提供應用模型。

專有名詞介紹

LayerNorm 對指定尾端維度正規化；backward 計算梯度；rstd 是標準差倒數；output_mask 指定需要哪些梯度輸出。

未指派、無討論；未查得對應 PR。Input／Output 依 ATen schema，驗收範圍待確認。

05. (build operator) 新增 native_layer_norm_backward portable kernel

原始議題 ↗ portable 註冊 ↗ ATen schema ↗

重點功能

新增可由 portable runtime 呼叫的 native_layer_norm_backward.out。

Input

上游梯度、原輸入、正規化形狀、mean／rstd、可選權重與偏置、輸出遮罩；dtype 範圍待釐清。

Output

依遮罩產生輸入、權重與偏置梯度，數值對齊 ATen；未要求輸出的 buffer 契約需確認。

未指派、無討論；未查得對應 PR。Input／Output 依 ATen schema，驗收範圍待確認。

06. (build operator) 新增 native_group_norm_backward portable kernel

原始議題 ↗ portable 註冊 ↗ ATen schema ↗

問題釐清

議題要求 native_group_norm_backward.out。現行 portable 註冊已有 GroupNorm 前向，尚未列其 backward；需要群組正規化梯度的 CPU 圖缺少此入口。

可能解法

待驗證方案：依各群組統計量計算梯度，再累加權重與偏置梯度；先以 ATen 對照小張量，確認 group、output_mask 及可選 weight 的邊界。

應用場景

適用於使用 GroupNorm 的裝置端訓練或反向圖。原議題未提供模型與硬體；可先在主機 CPU 驗證語意，再確認目標裝置需求。

專有名詞介紹

GroupNorm 把通道分組後正規化；N／C／HxW 表示批次、通道與空間元素數；梯度描述輸入或參數變動如何影響結果。

未指派、無討論；未查得對應 PR。原文需求簡短，不能視為完整驗收規格。

06. (build operator) 新增 native_group_norm_backward portable kernel

原始議題 ↗ portable 註冊 ↗ ATen schema ↗

重點功能

新增 native_group_norm_backward.out 的 portable 實作與對應註冊。

Input

上游梯度、輸入、mean／rstd、可選 weight、N／C／HxW、group 與輸出遮罩；必要 dtype 待確認。

Output

輸入、權重與偏置的梯度，遵守輸出遮罩並對齊 ATen；空群組與 buffer 驗收條件待釐清。

未指派、無討論；未查得對應 PR。原文需求簡短，不能視為完整驗收規格。

07. (build operator) 讓 Python runtime 可直接呼叫 kernel

原始議題 ↗ 目前 Python API ↗

問題釐清

議題提出從 Python 取得、呼叫與動態註冊 kernel。現行 OperatorRegistry 可列 operator_names，但仍有「Expose the kernel callables」TODO，直接呼叫能力未完成。

可能解法

議題方案是建立 Kernel／OperatorRegistry 綁定，將引數轉成 EValue 後呼叫。建議先交付可查找與呼叫的最小介面，再確認動態註冊及 metadata 的 API 契約。

應用場景

適用於 kernel 開發者在 Python 做單元測試與微型基準測試；可直接觀察 ExecuTorch kernel 的結果，減少每次建立完整模型的步驟。

專有名詞介紹

pybind 是 Python 與 C++ 的介面；EValue 是 runtime 傳遞的值容器；registry 記錄已註冊的 kernel；schema 描述引數與回傳型別。

未指派；未查得對應實作 PR。已有名稱查詢，直接呼叫與動態註冊仍須分段確認。

07. (build operator) 讓 Python runtime 可直接呼叫 kernel

原始議題 ↗ 目前 Python API ↗

重點功能

讓 Python runtime 可取得並直接呼叫已註冊的 ExecuTorch kernel。

Input

operator 名稱與符合 schema 的引數，例如 aten::add.out 及輸入、out 張量。

Output

執行所選 kernel 並回傳或寫入結果；查找不存在的 kernel 時回報錯誤。

未指派；未查得對應實作 PR。已有名稱查詢，直接呼叫與動態註冊仍須分段確認。

08. (build operator) 將 aten 命名的 prim ops 移入 portable

原始議題 ↗ 目前 prim 註冊 ↗

問題釐清

議題指出 runtime 已能處理非 out-variant kernel，提議讓回傳純量的 aten prim ops 改走 portable。現行 sym_size、sym_numel 等仍註冊在 prim_ops。

可能解法

待驗證方案：先選 sym_size 作遷移樣本，保留名稱、回傳語意與動態形狀行為，再驗證 codegen、selective build 與連結。完整遷移清單尚待確認。

應用場景

適用於需要動態形狀純量的 CPU 圖，以及維護 operator 註冊、精簡建置的開發者；此題直接涉及 kernel 歸屬與建置整合。

專有名詞介紹

prim op 是 runtime 基礎運算；SymInt 表示可符號化的整數；non-out variant 直接回傳值；selective build 僅納入模型所需算子。

未指派；未查得遷移實作 PR。不是新增同名算子，需保留既有行為與建置相容性。

08. (build operator) 將 aten 命名的 prim ops 移入 portable

原始議題 ↗ 目前 prim 註冊 ↗

重點功能

讓適合的 aten 命名純量運算經由 portable kernel 路徑執行。

Input

含該類運算的圖及其引數，例如 sym_size 的 tensor 與 dim；完整 operator 清單待釐清。

Output

回傳與既有 prim op 相同的純量結果，模型可正常執行；對舊模型的相容性驗收須先確認。

未指派；未查得遷移實作 PR。不是新增同名算子，需保留既有行為與建置相容性。

09. (build operator) 以量測改善 CMSIS-NN convolution 選擇

原始議題 ↗ 原始討論 ↗ 仍有 TODO ↗

問題釐清

現行 Cortex-M pass 已對 batch 與特定 MVE 單通道情況選擇路徑，但仍保留此 issue 的 benchmark TODO。普通與 depthwise convolution 何時較快尚缺完整量測。

可能解法

待驗證方案：在固定 MCU、編譯器與形狀下比較兩條合法路徑，依量測調整選擇條件。原討論的條件是提案；不能宣稱 depthwise 一定更快。

應用場景

適用於 Cortex-M 的量化 CNN，特別是不符合 SIMD 最佳化條件的 depthwise 層。需要可用 MCU 或相符模擬器；本輪沒有執行硬體效能測試。

專有名詞介紹

CMSIS-NN 是 Arm MCU 神經網路函式庫；depthwise convolution 逐通道卷積；SIMD 同時處理多筆資料；MVE 是 Arm 的向量指令擴充。

09. (build operator) 以量測改善 CMSIS-NN convolution 選擇

原始議題 ↗ 原始討論 ↗ 仍有 TODO ↗

重點功能

依實際量測改善普通／depthwise convolution 的 operator 選擇。

Input

可比較的卷積形狀、通道、dilation、batch，以及明確的 Cortex-M 目標與編譯設定。

Output

可重現的比較結果與選擇規則；維持數值正確，效能門檻及硬體範圍待確認。

未指派；原 depthwise PR 已合併，benchmark TODO 仍在。硬體可用性須先確認。

10. (quantization) 處理 XNNPACK group size 16 的線性量化

原始議題 ↗ 量化對齊限制 ↗ 替代方案討論 ↗

問題釐清

議題以 Gemma3 4B vision encoder 為例：部分 hidden dim 無法整除 32。現行 XNNPACK groupwise lowering 仍要求 group_size 為 32 的倍數，group 16 不能直接通過。

可能解法

原討論提出 group 16 kernel、padding，或不相容層改用 INT8。待驗證方案：先比較 padding 與混合精度的品質、記憶體及延遲，再確認是否需要 kernel 擴充。

應用場景

適用於 XNNPACK CPU 上部署 hidden dim 不整除 32 的視覺編碼器。討論的 8 GB pte 是當時紀錄，不能當成今日模型大小；此題也不重複既有 8da8w 設定修復。

專有名詞介紹

group size 是共用量化參數的權重群組長度；padding 補齊維度；8da4w／8da8w 使用動態 8-bit activation 與 4／8-bit weight。

目前未指派；未查得對應修復 PR。先確認舊混合精度規劃進度及未滿足的模型需求。

10. (quantization) 處理 XNNPACK group size 16 的線性量化

原始議題 ↗ 量化對齊限制 ↗ 替代方案討論 ↗

重點功能

讓目前受 group 對齊限制的線性層可採用合適的 XNNPACK 量化部署方案。

Input

hidden dim 不整除 32 的模型／線性層及量化設定；以 Gemma3 4B encoder 為來源例子，最小測例待補。

Output

可匯出並執行的量化模型；方案可為 group 16、padding 或混合精度，品質與效能須另驗證。

目前未指派；未查得對應修復 PR。先確認舊混合精度規劃進度及未滿足的模型需求。